Regresión Lineal Múltiple

Pronóstico del Precio de una Casa

Ulises Abraham Ortiz Sánchez

Contexto y Objetivo

El objetivo es **pronosticar el precio de venta de una casa** a partir de sus características observables. Para ello se construyó un modelo de regresión lineal múltiple estimado mediante mínimos cuadrados ordinarios (OLS), cuya solución analítica se resolvió de forma matricial. Este enfoque permite entender el fundamento matemático detrás del algoritmo, verificando que los resultados son idénticos a los que producen bibliotecas especializadas como statsmodels.

Variable objetivo

price — Precio de venta de una casa en dólares. Esta es la variable que el modelo intenta predecir a partir de las características físicas y cualitativas del inmueble.

Variables Seleccionadas y su Justificación

Se excluyeron previamente `id`, `date` (identificadores sin valor predictivo), `zipcode` (categórica sin escala lineal), `lat` / `long` (coordenadas crudas), `sqft_above` (colineal con `sqft_living`) y `yr_renovated` (~96% de valores en cero). Las 11 variables finales que ingresaron al proceso de selección estadística son:

Variable	Descripción	Por qué se incluyó
`bedrooms`	Número de habitaciones	Primer filtro de búsqueda para cualquier comprador.
`bathrooms`	Número de baños	Indicador de confort y capacidad de la vivienda.
`sqft_living`	Superficie habitable (ft^2)	Variable con mayor correlación individual con el precio.
`sqft_lot`	Superficie del terreno (ft^2)	El tamaño del lote agrega valor, aunque su efecto es menor.
`floors`	Número de pisos	Las casas de varios niveles suelen cotizarse más alto.
`waterfront`	Vista al agua (0/1)	Las propiedades frente al agua tienen una prima de precio muy significativa.
`view`	Calidad de la vista (0–4)	La percepción visual afecta directamente el atractivo y el precio.
`condition`	Estado de conservación (1–5)	Una casa en buen estado requiere menor inversión post-compra.
`grade`	Calidad de construcción (1–13)	Fuerte predictor del valor a largo plazo.
`sqft_basement`	Superficie del sótano (ft^2)	Espacio adicional con múltiples usos posibles.
`yr_built`	Año de construcción	La antigüedad afecta valor y costos de mantenimiento esperados.

2° Intento

Eliminación de Variables No Significativas

Se aplicó el método de **eliminación hacia atrás**: se parte del modelo completo con las 11 variables y se elimina iterativamente la variable con el mayor p-value mientras éste supere el umbral $\alpha = 0.05$. El proceso finaliza cuando *todas* las variables restantes son estadísticamente significativas ($p \leq 0.05$).

Iteración 1 — 11 variables activas

Se ajusta el modelo completo y se revisan los p-values de cada predictor:

Variable	Coeficiente	p-value	Significativa
`Intercepto`	6,214,667.16	< 0.0001	✓
`bedrooms`	−34,440.26	< 0.0001	✓
`bathrooms`	44,223.36	< 0.0001	✓
`sqft_living`	162.82	< 0.0001	✓
`sqft_lot`	−0.24	< 0.0001	✓
`floors`	27,629.45	< 0.0001	✓
`waterfront`	563,509.94	< 0.0001	✓
`view`	43,344.84	< 0.0001	✓
`condition`	16,611.91	< 0.0001	✓
`grade`	123,673.21	< 0.0001	✓
`sqft_basement`	0.35	0.3967	✗ p = 0.3967 — ELIMINAR
`yr_built`	−3,576.27	< 0.0001	✓

▶ Eliminar `sqft_basement` — p-value = 0.3967 > 0.05

Justificación: no existe evidencia de que el área del sótano aporte información adicional al precio una vez controladas las demás variables. Su coeficiente (0.35) es prácticamente nulo y su p-value (0.3967) es muy superior al umbral de significancia.

Iteración 2 — 10 variables activas · MODELO FINAL

Se re-ajusta el modelo sin `sqft_basement`. Todos los p-values son ≤ 0.05:

Variable	Coeficiente	p-value	Significativa
`Intercepto`	6,216,011.72	< 0.0001	✓
`bedrooms`	−34,441.54	< 0.0001	✓
`bathrooms`	44,274.79	< 0.0001	✓
`sqft_living`	162.91	< 0.0001	✓
`sqft_lot`	−0.24	< 0.0001	✓
`floors`	27,512.42	< 0.0001	✓
`waterfront`	563,462.16	< 0.0001	✓
`view`	43,372.89	< 0.0001	✓
`condition`	16,625.68	< 0.0001	✓
`grade`	123,645.98	< 0.0001	✓
`yr_built`	−3,576.88	< 0.0001	✓

Criterio de parada: todas las variables tienen p-value ≤ 0.05

Resultado del proceso

- Variables iniciales: **11**
- Variable eliminada: **sqft_basement** ($p = 0.3967$, iteración 1)
- Variables en el modelo final: **10**
- El proceso convergió en **2 iteraciones**

2° Intento

Comparación Detallada: Modelo Matricial vs. OLS Automatizado

Una vez obtenida la ecuación mediante la fórmula $\boldsymbol{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$, se validó contra el reporte completo de `statsmodels.OLS`.

Tabla Comparativa de Coeficientes (modelo final — 10 variables)

Variable	Coef. Manual (β matricial)	Coef. OLS (statsmodels)	Δ diferencia	Error estándar	t-stat	p-value	IC 95% inf.	IC 95% sup.	Sig.
`Intercepto`	6,216,011.72	6,216,011.72	≈ 0	149,502.62	41.58	<0.0001	5,922,968.51	6,509,054.93	✓
`bedrooms`	−34,441.54	−34,441.54	≈ 0	2,311.66	−14.90	<0.0001	−38,972.81	−29,910.27	✓
`bathrooms`	44,274.79	44,274.79	≈ 0	4,103.07	10.79	<0.0001	36,232.35	52,317.23	✓
`sqft_living`	162.91	162.91	≈ 0	3.36	48.50	<0.0001	156.33	169.49	✓
`sqft_lot`	−0.2383	−0.2383	≈ 0	0.0404	−5.90	<0.0001	−0.317	−0.159	✓
`floors`	27,512.42	27,512.42	≈ 0	4,407.90	6.24	<0.0001	18,872.36	36,152.48	✓
`waterfront`	563,462.16	563,462.16	≈ 0	19,986.42	28.19	<0.0001	524,286.19	602,638.13	✓
`view`	43,372.89	43,372.89	≈ 0	2,721.92	15.93	<0.0001	38,037.52	48,708.26	✓
`condition`	16,625.68	16,625.68	≈ 0	2,923.22	5.69	<0.0001	10,895.67	22,355.69	✓
`grade`	123,645.98	123,645.98	≈ 0	2,795.07	44.24	<0.0001	118,167.17	129,124.79	✓
`yr_built`	−3,576.88	−3,576.88	≈ 0	76.29	−46.89	<0.0001	−3,726.41	−3,427.35	✓

Evaluación del Modelo

El dataset se dividió en un conjunto de entrenamiento (70%) y uno de prueba (30%), y se calculó el coeficiente de determinación R^2 sobre ambos.

65.1%	65.3%	2,566	10
R^2 — Entrenamiento	R^2 — Prueba	Estadístico F	Variables finales

Histograma de Residuales — Base de Prueba

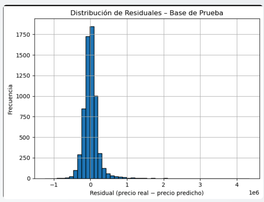

Conclusiones

La calidad supera al tamaño

Aunque `sqft_living` sí importa, los coeficientes muestran que `waterfront` (+$563K) y `grade` (+$123K por nivel) tienen un impacto económico mucho mayor en el mercado de King County.

El modelo captura los patrones principales

Con un R^2 consistente del ~65% en entrenamiento y prueba, el modelo es confiable para estimar precios en rangos intermedios. La pequeña brecha entre ambas métricas confirma que no hay sobreajuste.

Álgebra matricial = OLS exacto

Los coeficientes calculados manualmente con NumPy son idénticos a los de statsmodels (diferencia $< 10^{-9}$), confirmando que $\beta = (X'X)^{-1}X'Y$ es la base matemática exacta de la regresión lineal múltiple.

Depuración por p-value

El proceso de eliminación hacia atras eliminó `sqft_basement` en la primera iteración ($p = 0.3967$). Las 10 variables restantes son todas más significativas ($p < 0.0001$), lo que garantiza que el modelo no incluye predictores redundantes o poco justificables.

Validación cruzada: manual vs. automático

La tabla comparativa confirma que los coeficientes, errores estándar, t-stats, p-values e intervalos de confianza al 95% son equivalentes entre el cálculo matricial y el reporte OLS de statsmodels, evidenciando comprensión profunda del método.